

LAPORAN TEKNIS KOMPREHENSIF



Platform Prediktif Berbasis AI

untuk

Deteksi Dini & Intervensi Resiko Keteringgalan Siswa

OLEH TEAM DATA SCIENTIST
KELOMPOK : CC26-PSU030

Melvin Nagasari CDCC325D6Y0626

Louis Aurelius CDCC325D6Y2651

1. Executive Summary

Learn Guard adalah platform prediktif berbasis kecerdasan buatan yang dirancang untuk mendeteksi risiko ketertinggalan siswa pada sistem pendidikan jarak jauh secara dini. Dengan memanfaatkan data aktivitas Virtual Learning Environment (VLE) hanya dalam 4 minggu pertama perkuliahan, platform ini mampu mengidentifikasi siswa yang berisiko gagal atau drop out sebelum kondisi tersebut sulit untuk diperbaiki.

Proyek ini menggunakan dataset OULAD (Open University Learning Analytics Dataset) yang mencakup data dari 27.795 siswa dengan 32 fitur perilaku dan demografi. Model terbaik yang dikembangkan adalah XGBoost dengan ROC-AUC sebesar 0.7212 dan F1-Score Macro 0.6591, mengalahkan Gradient Boosting, Random Forest, dan Logistic Regression.

Total Siswa	Risk Rate	ROC-AUC	Optimal Threshold
27.795	45.5%	0.7212	0.55

Sumber data:

Dataset	OULAD (Open University Learning Analytics)
Sumber	https://archive.ics.uci.edu/dataset/349/open+university+learning+analytics+dataset
Waktu Akses	Sabtu, 28 Maret 2026, 4:16:33 (UTC+7 time)
Metode Utama	Machine Learning (XGBoost)
Periode Analisis	4 Minggu Pertama Perkuliahan
Tahun	2026

2. Problem Discovery & Strategy

2.1 Identifikasi Masalah

Sistem pendidikan jarak jauh menghadapi tantangan fundamental dalam memantau perkembangan belajar siswa secara real-time. Berbeda dengan kelas tatap muka, instruktur tidak dapat mengamati langsung tanda-tanda ketertinggalan seperti ketidakhadiran, kurangnya partisipasi, atau ekspresi kebingungan. Akibatnya, intervensi akademik sering terlambat dilakukan ketika siswa sudah berada di ambang kegagalan.

Permasalahan utama yang diidentifikasi meliputi:

- Keterlambatan deteksi risiko: instruktur baru mengetahui siswa berisiko setelah nilai akhir keluar
- Tidak adanya sistem peringatan dini yang berbasis data perilaku belajar
- Keterbatasan sumber daya: instruktur tidak mampu memantau ratusan siswa secara individual
- Tingginya angka drop out pada platform e-learning yang merugikan institusi dan siswa

2.2 Solusi yang Diusulkan

Learn Guard hadir sebagai solusi platform prediktif yang menganalisis pola perilaku interaksi siswa pada VLE dalam 4 minggu pertama perkuliahan. Platform ini menghasilkan risk score per siswa yang dapat digunakan instruktur untuk memprioritaskan intervensi sebelum terlambat.

2.3 Research Questions

1. Faktor demografi dan perilaku interaksi pada VLE apa saja yang paling berpengaruh terhadap risiko kegagalan atau drop out siswa?
2. Sejauh mana data aktivitas awal (4–8 minggu pertama) dapat digunakan untuk memprediksi status akhir siswa?
3. Model machine learning apa yang memberikan performa terbaik dalam mendeteksi siswa berisiko secara dini?

2.4 Pertanyaan Bisnis

Pertanyaan Bisnis 1

Berapa rata-rata jumlah klik (sum_click) mingguan pada 4 minggu pertama yang membedakan antara siswa yang lulus (Pass/Distinction) dengan siswa yang berisiko (Fail/Withdrawn)?

Pertanyaan Bisnis 2

Bagaimana korelasi antara selisih waktu pengumpulan tugas pertama (date_submitted vs date_deadline) dengan skor akhir yang diperoleh siswa?

Pertanyaan Bisnis 3

Kelompok demografi mana (highest_education atau disability) yang menunjukkan penurunan aktivitas interaksi VLE paling drastis selama 4 minggu pertama perkuliahan?

3. Data Preparation (End-to-End Wrangling)

3.1 Gathering Data

Dataset yang digunakan adalah OULAD (Open University Learning Analytics Dataset), sebuah dataset publik dari Open University UK yang tersedia di Kaggle. Dataset ini mencakup 7 tabel relasional yang merekam aktivitas siswa pada platform e-learning.

Tabel	Deskripsi	Ukuran
studentInfo.csv	Demografi dan hasil akhir siswa	32.593 baris
studentVle.csv	Log aktivitas harian VLE	10.655.280 baris
studentAssessment.csv	Skor dan waktu submit tugas	173.912 baris
assessments.csv	Detail deadline assessment	206 baris
courses.csv	Course yang tersedia dan presentasi	22 baris
studentRegistration.csv	Informasi tentang waktu pendaftaran mahasiswa untuk presentasi modul	32.593 baris
vle.csv	Informasi tentang materi yang tersedia di VLE.	6.364 Baris

Tantangan utama pada tahap ini adalah ukuran **studentVle.csv** yang sangat besar (>10 juta baris). Solusi yang diterapkan adalah teknik *chunked processing* dengan ukuran *chunk* 500.000 baris, di mana agregasi mingguan dilakukan di dalam loop untuk menghindari *memory overflow*.

3.2 Assessing Data

Evaluasi kualitas data menghasilkan temuan sebagai berikut:

Dimensi	Temuan	Severity	Penanganan
Missing Values (score)	24.19% (23.440 baris)	Medium	Dibiarkan NaN = tidak submit
Missing Values (total_clicks)	4.95% (4.798 baris)	Low	Diisi 0 (tidak ada aktivitas)
Duplikasi Data	0 baris	None	Tidak perlu penanganan
Outlier (total_clicks)	~20% data	Low	Flag <code>is_high_activity</code>
Negative Weeks	Pre-enrollment activity	Medium	Filter <code>date >= 1</code> di kode 1

3.3 Cleaning Data

Pipeline cleaning yang diterapkan secara berurutan:

1. Filter aktivitas valid: `date >= 1` dan `date <= 27` untuk mendapatkan week 1-4 bersih

2. Agregasi mingguan: log harian diagregasi menjadi total_clicks per siswa per minggu
3. Merge tabel: studentInfo + studentVle_aggregated + studentAssessment + assessments
4. Penanganan missing values: total_clicks NaN diisi 0, week NaN di drop
5. Validasi range: total_clicks tidak boleh negatif, score harus 0-100
6. Feature engineering awal: is_submitted, is_late, is_high_activity, risk_label

Hasil akhir pipeline menghasilkan dua dataset utama:

- df_master_weekly_clean: 92.088 baris × 17 kolom (format per minggu)
- df_final: 27.795 baris × 18 kolom (format per siswa, siap untuk modeling)

4. Exploratory Data Analysis (EDA)

4.1 Overview Dataset

Distribusi target variable menunjukkan class imbalance moderat dengan rasio 54.5% aman (Pass/Distinction) vs 45.5% berisiko (Fail/Withdrawn). Rasio ini cukup seimbang untuk tidak memerlukan teknik oversampling seperti SMOTE, namun tetap membutuhkan `class_weight='balanced'` pada model.

Distribusi minggu sangat merata ($\pm 25\%$ per minggu) memastikan tidak ada bias temporal:

Minggu 1	Minggu 2	Minggu 3	Minggu 4
22.963 baris (24.9%)	23.168 baris (25.2%)	23.822 baris (25.9%)	22.135 baris (24.0%)

4.2 Pertanyaan Bisnis 1: Rata-rata Klik Mingguan per Grup Risiko

Analisis aktivitas klik pada 4 minggu pertama menunjukkan perbedaan signifikan antara kedua kelompok siswa:

Grup	Week 1	Week 2	Week 3	Week 4	Rata-rata
Pass/Distinction	89.22	90.42	108.08	86.27	87.66
Fail/Withdrawn	58.60	59.69	81.19	58.44	57.39
Selisih	30.62	30.73	26.89	27.83	30.27

Insight Pertanyaan Bisnis 1

Siswa Pass/Distinction rata-rata mengklik 44.7% lebih banyak dari Fail/Withdrawn secara konsisten di semua 4 minggu. Perbedaan ini signifikan secara statistik (Welch's t-test $p < 0.001$). Minggu 3 adalah puncak aktivitas kedua kelompok, kemungkinan karena deadline assessment.

4.3 Pertanyaan Bisnis 2: Korelasi Waktu Submit vs Skor Akhir

Analisis korelasi antara `days_diff` (selisih submit vs deadline) dan `score` menghasilkan temuan yang counter-intuitive namun bermakna:

Metrik	Nilai	Interpretasi	Kekuatan
Pearson r (overall)	-0.0541	Sangat lemah	Tidak signifikan praktis
Spearman r (overall)	-0.1429	Sangat lemah	Tidak signifikan praktis
Mean score (On Time/Early)	73.80	Lebih tinggi 6 poin	Lemah
Mean score (Late)	67.80	Lebih rendah 6 poin	Lemah
Proporsi terlambat	25.2%	1 dari 4 siswa terlambat	-

**Insight
Pertanyaan
Bisnis 2**

days_diff bukan prediktor kuat untuk skor akhir (korelasi sangat lemah). Namun secara praktis, siswa yang submit lebih awal rata-rata mendapat skor 6 poin lebih tinggi. Fitur ini tidak akan menjadi kontributor utama di model ML.

4.4 Pertanyaan Bisnis 3: Penurunan Aktivitas per Kelompok Demografi

Analisis penurunan aktivitas dari minggu puncak (minggu 3) ke minggu 4 berdasarkan kelompok demografi:

Berdasarkan Tingkat Pendidikan (highest_education)

Kelompok	Week 1	Week 2	Week 3	Week 4	Drop W3->W4
Post Graduate Qualification	90.96	91.59	119.71	84.55	29.4%
No Formal Quals	76.70	64.07	89.13	65.71	26.3%
HE Qualification	84.14	87.24	109.60	82.06	25.1%
A Level or Equivalent	73.50	74.53	94.48	72.23	23.6%
Lower Than A Level	75.44	77.10	93.82	75.63	19.4%

Risk Rate per Kelompok Pendidikan

Kelompok	Risk Rate	Status
No Formal Quals	63.0%	Paling Berisiko
Lower Than A Level	53.9%	Sangat Berisiko
A Level or Equivalent	41.0%	Moderat
HE Qualification	36.9%	Relatif Aman
Post Graduate Qualification	30.7%	Paling Aman

**Insight
Pertanyaan
Bisnis 3**

Kelompok No Formal Quals memiliki risk rate tertinggi (63%) meski bukan yang paling besar penurunan aktivitasnya. Post Graduate Qualification mengalami penurunan terbesar (29.4%) namun risk rate terendah (30.7%), mereka aktif saat deadline lalu efisien setelahnya. Siswa dengan disabilitas justru lebih stabil (drop 18.9%) dibanding tanpa disabilitas (22.7%).

5. Feature Engineering & Model Readiness

5.1 Feature Engineering

Fitur-fitur yang dikembangkan untuk model machine learning:

Fitur	Tipe	Deskripsi	Kategori
click_w1 - click_w4	Integer	Total klik per minggu (fitur utama)	Behavior
avg_clicks	Float	Rata-rata klik per minggu selama 4 minggu	Behavior
total_clicks	Integer	Total klik selama 4 minggu pertama	Behavior
active_weeks	Integer	Jumlah minggu siswa aktif berinteraksi (1–4)	Behavior
click_trend	Float	Selisih klik minggu 4 vs minggu 1	Trend
click_growth_rate	Float	Rasio pertumbuhan klik: $(w4-w1)/(w1+1)$	Trend
is_submitted	Integer	Pernah submit tugas: 1=Ya, 0=Tidak	Engagement
is_late	Integer	Pernah terlambat submit: 1=Ya, 0=Tidak	Engagement
highest_education_*	Integer	Dummy encoding tingkat pendidikan (drop_first=True)	Demografi
gender_*, age_band_*, disability_*, region_*	Integer	Dummy encoding variabel demografi lainnya	Demografi

5.2 Korelasi Fitur vs Target

Urutan fitur berdasarkan kekuatan korelasi dengan risk_label (Pearson):

- active_weeks: -0.2698 (terkuat, konsistensi kehadiran adalah prediktor utama)
- total_clicks: -0.2149 (kedua terkuat)
- avg_clicks: -0.1908
- click_w2: -0.1848
- click_w4: -0.1845
- click_w3: -0.1630
- click_w1: -0.1610
- click_growth_rate: -0.0003 (tidak bermakna)
- click_trend: +0.0045 (tidak bermakna)
- Fitur demografi: kontribusi kecil, highest_education paling informatif

6. Model Machine Learning

6.1 Setup & Konfigurasi

Konfigurasi eksperimen yang digunakan:

- Train/Test Split: 80%/20% dengan stratified sampling
- Cross Validation: StratifiedKFold 5-fold
- Metrik Utama: ROC-AUC, F1-Score Macro, Recall kelas 1
- Imbalanced Handling: class_weight='balanced' (RF & LR), scale_pos_weight (XGBoost)

6.2 Hasil Cross Validation

Model	AUC (CV Mean)	Std	Ranking
XGBoost	0.7205	±0.0058	#1
Gradient Boosting	0.7199	±0.0067	#2
Random Forest	0.7164	±0.0059	#3
Logistic Regression	0.7098	±0.0043	#4

6.3 Hasil Test Set

Model	ROC-AUC	F1 Macro	Recall (1)	Precision (1)
Gradient Boosting	0.7212	0.6565	0.6254	0.6259
XGBoost	0.7210	0.6591	0.6250	0.6298
Logistic Regression	0.7118	0.6582	0.6314	0.6264
Random Forest	0.7159	0.6506	0.6168	0.6202

6.4 Pemilihan Model Final & Threshold Optimization

XGBoost dipilih sebagai model produksi karena memiliki F1-Score Macro tertinggi (0.6591), AUC hampir sama dengan GBM (selisih hanya 0.0008), lebih ringan saat inference, dan mudah di-serialize untuk deployment API.

Optimal threshold ditetapkan pada 0.55 (dari default 0.50) berdasarkan optimasi F1-Score Macro. Threshold ini memberikan keseimbangan terbaik antara precision dan recall untuk kedua kelas.

6.5 Feature Importance (Top 10)

Rank	Fitur	Importance Score
1	click_w4	0.1324
2	total_clicks	0.1143
3	click_w2	0.1112
4	active_weeks	0.0924

Rank	Fitur	Importance Score
5	avg_clicks	0.0780
6	click_w3	0.0729
7	click_w1	0.0694
8	highest_education_Lower_Than_A_Level	0.0588
9	click_growth_rate	0.0503
10	click_trend	0.0426

Insight Model

Fitur behavior (klik) mendominasi top 7 feature importance, mengkonfirmasi temuan Pertanyaan Bisnis 1. Fitur demografi (highest_education) masuk di posisi 8, konsisten dengan Pertanyaan Bisnis 3. Fitur trend (click_trend, click_growth_rate) berkontribusi kecil, sejalan dengan hasil korelasi yang mendekati nol.

7. Dashboard Interaktif (Streamlit)

7.1 Deskripsi Dashboard

Dashboard interaktif dikembangkan menggunakan Streamlit sebagai prototype untuk mempresentasikan temuan EDA dan kesimpulan analisis secara visual dan interaktif. Dashboard terdiri dari empat section utama yang mencakup seluruh hasil analisis.

7.2 Struktur Dashboard

Section	Konten	Fitur Interaktif
Overview	4 metric cards, pie chart, bar chart distribusi	Real-time metrics dari data
Pertanyaan Bisnis 1 Analysis	Line chart, bar chart, box plot	Filter minggu (multiselect 1–4)
Pertanyaan Bisnis 2 Analysis	Box plot, scatter plot + regression line	Metric korelasi otomatis
Pertanyaan Bisnis 3 Analysis	Line chart tren, bar chart risk rate, tabel drop	Dropdown pilih variabel demografi dan disabilitas

Dashboard dijalankan dengan perintah: streamlit run [dashboard.py](#)

atau pada link: <https://learning-guard-data.streamlit.app/>

8. Kesimpulan & Rekomendasi

8.1 Jawaban Research Questions

RQ1: Faktor yang Paling Berpengaruh

Faktor perilaku (behavioral) terbukti jauh lebih berpengaruh dibanding faktor demografi. `active_weeks` adalah prediktor terkuat dengan korelasi -0.2698 terhadap `risk_label`, artinya konsistensi kehadiran mingguan lebih prediktif dibanding besaran klik itu sendiri. Diikuti oleh `total_clicks` (-0.2149) dan `avg_clicks` (-0.1908) yang juga berkontribusi signifikan. Di antara faktor demografi, `highest_education` adalah yang paling informatif, khususnya kelompok No Formal Quals (risk rate 63%) dan Lower Than A Level (risk rate 53.9%).

RQ2: Prediksi dengan Data 4 Minggu Pertama

Data aktivitas 4 minggu pertama terbukti cukup untuk membangun model prediktif dengan ROC-AUC 0.72. Ini berarti dengan hanya mengetahui perilaku siswa dalam satu bulan pertama, sistem dapat mengidentifikasi 62.5% siswa yang akan berisiko gagal dengan precision 62.9%, memberikan cukup waktu untuk intervensi akademik.

RQ3: Model Terbaik

XGBoost memberikan performa terbaik secara keseluruhan dengan F1-Score Macro 0.6594 dan ROC-AUC 0.7210 pada test set, dengan AUC cross-validation 0.7198 ± 0.0058 yang menunjukkan stabilitas tinggi. XGBoost unggul dibanding Gradient Boosting, Random Forest, dan Logistic Regression untuk kasus tabular data dengan skala sedang ini.

8.2 Rekomendasi

Untuk Tim Akademik / Instruktur

- Prioritaskan intervensi untuk siswa dengan klik < 58 kali/minggu di minggu 1-2
- Perhatikan khusus kelompok No Formal Quals dan Lower Than A Level yang memiliki risk rate >50%
- Gunakan risk score sebagai panduan, bukan keputusan final, tetap lakukan assessment individual

Untuk Pengembangan Selanjutnya

- Tambahkan data minggu 5-10 untuk meningkatkan akurasi prediksi
- Eksplorasi agregasi harian (bukan mingguan) untuk fitur yang lebih granular
- Implementasikan re-training otomatis setiap awal semester dengan data terbaru
- Pertimbangkan model ensemble (voting antara XGBoost dan GBM) untuk meningkatkan robustness

8.3 Keterbatasan Proyek

- Data hanya mencakup 4 minggu pertama, prediksi mungkin kurang akurat untuk siswa yang terlambat aktif

- Dataset OULAD berasal dari UK (Open University) sehingga generalisasi ke konteks lain perlu validasi
- Fitur timestamp harian tidak tersedia di OULAD sehingga distribusi waktu belajar tidak bisa dianalisis
- Deep learning tidak optimal untuk skala dataset ini (27.795 baris) dibanding tree-based models
- Persiapkan perangkat dengan kapasitas komputasi yang besar

9. Artifacts & Deliverables

9.1 File yang Dihasilkan

File	Tipe	Deskripsi
studentVle_aggregated.csv	CSV	Agregasi mingguan studentVle (hasil chunked processing)
df_master_weekly.csv	CSV	Master dataset setelah merge semua tabel (format long)
df_master_weekly_clean.csv	CSV	Dataset bersih per minggu, digunakan untuk EDA
df_final.csv	CSV	Dataset per siswa (1 baris per siswa), untuk analisis & AI Engineer
df_model.csv	CSV	Dataset siap ML: encoded, engineered, 32 fitur, untuk AI Engineer
model_xgboost.pkl	PKL	Model XGBoost final (trained on full data, 32 fitur)
threshold.pkl	PKL	Optimal threshold = 0.55 untuk prediksi biner
feature_names.pkl	PKL	Daftar 32 nama fitur yang digunakan model (urutan harus sama)
data_dictionary_learnguard.xlsx	XLSX	Data dictionary lengkap 3 tabel + README untuk AI Engineer
dashboard.py	PY	Streamlit dashboard interaktif (4 section, Pertanyaan Bisnis 1-Pertanyaan Bisnis 3 + Overview)